

TUGAS 3

LAPORAN STATISTIKA SPASIAL

**“Analisis Data Indeks Pembangunan Manusia di Jawa Barat pada Tahun 2021
Dengan Metode GWR (*Geographically Weighted Regression*)”**



Disusun oleh:

- | | |
|----------------------------------|------------|
| 1. Ammar Yazid Daffala | 1906377851 |
| 2. Aprilia Rahmawati | 1906299433 |
| 3. Hunaiva Kintan Dahlan | 1906375695 |
| 4. Michael Mario Bramanthyo Adhi | 1906299534 |

PROGRAM STUDI STATISTIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS INDONESIA

DEPOK

2022

ABSTRAK

Indeks Pembangunan Manusia (IPM) menjelaskan bagaimana penduduk dapat mengakses hasil pembangunan dalam memperoleh pendapatan, kesehatan, pendidikan, dan sebagainya. Pembangunan manusia di Provinsi Jawa Barat pada tahun 2021 terus mengalami kemajuan yang ditandai dengan peningkatan IPM Provinsi Jawa Barat dari tahun ketahun dan dibutuhkan perhatian untuk dapat terus lebih baik. IPM dipengaruhi oleh faktor bervariasi di setiap daerah sehingga digunakan *Geographically Weighted Regression* (GWR). GWR mengatasi masalah heterogenitas spasial dengan membangun model regresi di setiap lokasi observasi. Penelitian ini menggunakan IPM Jawa Barat (Y) sebagai peubah terikat dan peubah bebasnya adalah Pengeluaran per Kapita (X_1), Harapan Lama Sekolah (X_2), dan Persentase Penduduk Miskin (X_3). Berdasarkan hasil analisis, pada aspek spasial data telah memenuhi asumsi heterogenitas spasial menggunakan Uji *Breusch Pagan*. Digunakan fungsi pembobot spasial GWR yaitu Kernel Gaussian dan Kernel Bisquare, yang menunjukkan hasil bahwa Kernel Gaussian lebih baik berdasarkan skor AIC dan R^2 . Model GWR menghasilkan hasil untuk 27 Kabupaten/Kota di Jawa Barat.

Kata kunci: Indeks Pembangunan Manusia (IPM), *Geographically Weighted Regression* (GWR), Pengeluaran per Kapita, Harapan Lama Sekolah, Persentase Penduduk Miskin

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Pembangunan manusia pada dasarnya memiliki makna yang luas. Namun ide dasar pembangunan manusia merupakan pertumbuhan positif dalam bidang ekonomi, sosial, politik, budaya, dan lingkungan, serta perubahan dalam kesejahteraan manusia. Manusia menjadi titik pusat (*central*) pembangunan, sementara upaya pembangunan manusia adalah sarana untuk mencapai tujuan itu. Oleh karena itu pembangunan mestinya dianalisis serta dipahami dari sudut manusianya, bukan sekedar pertumbuhan ekonomi. Pandangan bahwa peningkatan kualitas sumber daya manusia mempunyai implikasi bahwa manusia merupakan titik *central* pembangunan semakin luas diterima oleh berbagai pihak. Hal ini mendorong terciptanya kerja sama dan koordinasi antar berbagai sektor pembangunan, karena setiap usaha yang dilakukan oleh masing-masing sektor pada hakekatnya adalah untuk meningkatkan kualitas dan kesejahteraan manusia.

Pada tahun 1990, *United Nations Development Programme* (UNDP) memperkenalkan suatu ukuran standar pembangunan manusia yaitu berupa Indeks Pembangunan Manusia (IPM) atau *Human Development Index* (HDI). IPM merupakan indikator penting untuk mengukur keberhasilan dalam upaya membangun kualitas hidup manusia. Selain itu, IPM juga dapat menentukan peringkat atau level pembangunan suatu wilayah/negara. Di Indonesia, IPM dapat menjadi ukuran kinerja Pemerintah dan juga menjadi salah satu yang mengalokasikan penentu Dana Alokasi Umum (DAU).

Pembangunan manusia di Provinsi Jawa Barat pada tahun 2021 mengalami peningkatan yang ditandai dengan meningkatnya Indeks Pembangunan Manusia (IPM) Provinsi Jawa Barat mencapai nilai 72.45 yang mana angka tersebut meningkat sebesar 0.36 poin dibanding tahun sebelumnya yang berada pada nilai 72.09. Sejak tahun 2016, status pembangunan manusia Jawa Barat, meningkat dari level sedang menjadi tinggi. Selama 2010-2021 IPM Jawa Barat rata-rata meningkat sebesar 0.83 persen per tahun, dari 66.15 pada tahun 2010 menjadi 72.45 pada tahun 2021.

Pada penelitian ini diharapkan diketahui hubungan antara IPM di setiap kabupaten/kota di Provinsi Jawa Barat dengan faktor-faktor yang memengaruhinya. Metode regresi yang menggunakan pertimbangan geografis adalah metode *Geographically Weighted Regression* (GWR).

1.2 Rumusan Masalah

Rumusan masalah dalam penelitian ini adalah:

1. Bagaimana memodelkan hubungan Indeks Pembangunan Manusia (IPM) dengan faktor-faktor yang memengaruhinya di Provinsi Jawa Barat dengan menggunakan metode *Geographically Weighted Regression* (GWR)?
2. Bagaimana perbandingan model *Geographically Weighted Regression* (GWR) yang dihasilkan menggunakan fungsi Kernel Gaussian dan fungsi Kernel Bisquare dalam menganalisis data Indeks Pembangunan Manusia (IPM) dengan faktor-faktor yang memengaruhinya di Jawa Barat.

1.3 Tujuan

Tujuan yang ingin diperoleh dalam penelitian ini adalah:

1. Memodelkan hubungan Indeks Pembangunan Manusia (IPM) dengan faktor-faktor yang memengaruhinya di Jawa Barat menggunakan metode *Geographically Weighted Regression* (GWR).
2. Membandingkan model *Geographically Weighted Regression* (GWR) yang dihasilkan menggunakan fungsi Kernel Gaussian dan fungsi Kernel Bisquare dalam menganalisis data Indeks Pembangunan Manusia (IPM) dengan faktor-faktor yang memengaruhinya di Jawa Barat.

1.4 Metode Penelitian

Metode-metode yang digunakan pada penelitian ini meliputi studi literatur, pengumpulan data, dan analisis data. Pada tahap studi literatur, referensi yang digunakan berupa buku, jurnal, dan sumber terpercaya lainnya. Data yang digunakan pada penelitian ini adalah data sekunder yang diambil dari Badan Pusat Statistik (BPS) Provinsi Jawa Barat. Variabel dependen (Y) pada penelitian ini adalah Indeks Pembangunan Manusia (IPM), sedangkan variabel independennya berupa faktor-faktor yang diduga sebagai penentu indeks pembangunan manusia, yaitu pengeluaran per kapita (X_1), harapan lama sekolah (X_2), dan persentase penduduk miskin (X_3). Tahap selanjutnya yaitu menganalisis data yang telah terkumpul dengan menggunakan *software* Rstudio untuk menghasilkan model *Geographically Weighted Regression* (GWR) serta peta sebaran dugaan parameter model *Geographically Weighted Regression* (GWR).

BAB 2

LANDASAN TEORI

2.1 Konsep IPM dan Faktor Penyebab

IPM (Indeks Pembangunan Manusia) merupakan indikator penting untuk mengukur keberhasilan dalam upaya membangun kualitas hidup manusia (masyarakat/penduduk) karena dapat menjelaskan bagaimana penduduk dapat mengakses hasil pembangunan dalam memperoleh pendapatan, kesehatan, pendidikan, dan sebagainya. Nilai IPM suatu negara atau wilayah menunjukkan seberapa jauh negara atau wilayah tersebut telah mencapai sasaran yang ditentukan, yaitu harapan hidup saat lahir, pendidikan dasar bagi semua lapisan masyarakat (tanpa kecuali), dan tingkat pendapatan yang telah mencapai standar hidup layak. Semakin dekat nilai IPM suatu wilayah terhadap angka 100, semakin dekat jalan yang harus ditempuh untuk mencapai sasaran itu.

Faktor pertama yang mempengaruhi IPM adalah pendapatan per kapita. Jika terjadi peningkatan pada pendapatan per kapita masyarakat, maka daya beli masyarakat meningkat. Peningkatan daya beli masyarakat berarti kemampuan masyarakat memenuhi kebutuhan hidupnya, baik untuk pendidikan maupun untuk kesehatan meningkat. Peningkatan yang terjadi pada pemenuhan kebutuhan hidup masyarakat menunjukkan terjadinya peningkatan kesejahteraan masyarakat tersebut. Oleh karena itu pendapatan per kapita dapat digunakan untuk mengukur keberhasilan pembangunan manusia.

Faktor kedua yang mempengaruhi IPM adalah harapan lama sekolah. Harapan lama sekolah dapat digunakan untuk mengetahui kondisi pembangunan sistem pendidikan di berbagai jenjang yang ditunjukkan dalam bentuk lamanya pendidikan (dalam tahun) yang diharapkan dapat dicapai oleh setiap anak. Harapan lama sekolah dihitung pada usia 7 tahun ke atas sesuai dengan kebijakan pemerintah mengenai program wajib belajar, berdasarkan sumber data dari Survei Sosial Ekonomi Nasional (Susenas).

Faktor ketiga yang mempengaruhi IPM adalah persentase penduduk miskin. Kemiskinan dapat terjadi salah satunya adalah karena pengangguran. Besarnya tingkat pengangguran merupakan cerminan kurang berhasilnya pembangunan di suatu negara. Pengangguran akan menimbulkan efek mengurangi pendapatan masyarakat, dan itu akan mengurangi tingkat kemakmuran yang telah tercapai.

2.2 Regresi Linear Sederhana

2.2.1 Definisi dan Asumsi Regresi Linear Sederhana

Analisis regresi linier sederhana adalah hubungan secara linear antara satu variabel independen (X) dengan variabel dependen (Y). Tujuan dari metode ini adalah untuk memprediksi nilai Y untuk nilai X yang diberikan. Pada regresi sederhana biasanya data yang digunakan memiliki skala interval atau rasio. Dengan model regresi sederhana:

$$y = \beta_0 + \beta_1 x + \varepsilon \sim NIID(0, \sigma^2), i = 1, 2, \dots, n$$

Keterangan:

y : Variabel dependen

x : Variabel independen

β_0 : *Intercept* (Nilai y apabila $x = 0$)

β_1 : *Slope* (Perubahan nilai y untuk setiap 1 unit x)

ε : Komponen *error*

2.2.2 Pendugaan Parameter Regresi Linear Sederhana

Parameter yang tidak diketahui β_0, β_1 dalam model regresi linear biasanya diestimasi menggunakan metode kuadrat terkecil (*least squares method*). MKT dapat digunakan apabila asumsi-asumsi pada analisis regresi terpenuhi. Beberapa asumsi yang harus dipenuhi dalam analisis regresi linier adalah asumsi linieritas, asumsi independensi dan non-otokorelasi, asumsi normalitas, asumsi homoskedastisitas, dan asumsi non-multikolinieritas. Pada prinsipnya, metode kuadrat terkecil ini digunakan untuk memperkirakan semua nilai koefisien regresi β sedemikian rupa sehingga meminimalkan kuadrat residual ($\sum_{i=1}^n \varepsilon_i^2$).

Misalkan S adalah kuadrat residual, maka dapat dituliskan sebagai berikut:

$$S = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)$$

Untuk menentukan $\hat{\beta}_0$ dan $\hat{\beta}_1$ dengan cara mendiferensiasi S secara parsial terhadap masing-masing β_0 dan β_1 dan memaksimumkannya (menyema dengankan hasil diferensiasi dengan nol).

- Menentukan $\hat{\beta}_0$:

$$\frac{dS}{d\beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)$$

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\sum_{i=1}^n y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n x_i = 0$$

$$n\hat{\beta}_0 = \sum_{i=1}^n y_i + \hat{\beta}_1 \sum_{i=1}^n x_i$$

$$\hat{\beta}_0 = \sum_{i=1}^n \frac{y_i}{n} + \hat{\beta}_1 \sum_{i=1}^n \frac{x_i}{n}$$

Dengan demikian, taksiran bagi β_0 adalah:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- Menentukan $\hat{\beta}_1$:

$$\frac{dS}{d\beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i)$$

$$\sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$\left(\sum_{i=1}^n \frac{y_i}{n} + \hat{\beta}_1 \sum_{i=1}^n \frac{x_i}{n} \right) \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$\frac{1}{n} \left(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i \right) - \frac{\hat{\beta}_1}{n} \left(\sum_{i=1}^n x_i \right)^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 + \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right) = \sum_{i=1}^n x_i y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i + \sum_{i=1}^n y_i \right)$$

Dengan demikian, taksiran bagi β_1 adalah:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n x_i + \sum_{i=1}^n y_i)}{\left(\sum_{i=1}^n x_i^2 + \frac{1}{n} (\sum_{i=1}^n x_i)^2 \right)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

2.3 Regresi Linear Berganda

2.3.1 Definisi Regresi Linear Berganda

Analisis regresi berganda adalah suatu metode untuk meramalkan nilai pengaruh dua variabel independen atau lebih terhadap satu variabel dependen. Lebih mudahnya yaitu untuk membuktikan ada tidaknya hubungan antara dua variabel atau lebih dari dua variabel independen X_1, X_2, \dots, X_i terhadap satu variabel terikat Y . Dengan model regresi berganda:

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i; \quad \varepsilon_i \sim NIID(0, \sigma^2), i = 1, 2, \dots, n \quad (1)$$

Keterangan:

y_i	: Variabel dependen
$x_{i1}, x_{i2}, \dots, x_{ip}$: Variabel independen
$\beta_0, \beta_1, \dots, \beta_p$: Parameter
ε_i	: Komponen <i>error</i>

Asumsi-asumsi model regresi linear berganda:

Menurut Gujarati (2003) asumsi-asumsi pada model regresi linier berganda adalah sebagai berikut:

1. Model regresinya adalah linier dalam parameter.
2. Nilai rata-rata dari *error* adalah nol.
3. Variansi dari *error* adalah konstan (homoskedastik).
4. Tidak terjadi autokorelasi pada *error*.
5. Tidak terjadi multikolinieritas pada variabel bebas.
6. *Error* berdistribusi normal.

2.3.2 Pendugaan Parameter Regresi Linear Berganda

Parameter $\beta_0, \beta_1, \dots, \beta_k$ pada persamaan (1) tidak dapat diketahui secara pasti nilainya. Oleh karena itu persamaan (1) dapat diduga dengan model sebagai berikut:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip} \quad (2)$$

Menurut Hines dan Montgomery (1990) model regresi linier berganda pada persamaan (1) dapat ditulis dalam bentuk matriks,

$$Y = X\beta + \varepsilon$$

dimana,

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

Metode kuadrat terkecil digunakan untuk menduga β dengan meminimkan jumlah kuadrat galat. Jumlah kuadrat galat dalam notasi matriks adalah sebagai berikut:

$$\begin{aligned} \text{JK Galat} &= \varepsilon' \varepsilon \\ &= (Y - X\beta)'(Y - X\beta) \\ &= Y'Y - \beta'X'Y - Y'X\beta + \beta'X'X\beta \end{aligned}$$

Karena $\beta'X'Y$ merupakan matriks yang mempunyai ukuran 1×1 atau skalar, maka $(\beta'X'Y)' = Y'X\beta$. Sehingga didapatkan hasil:

$$\text{JK Galat} = Y'Y - 2\beta'X'Y + \beta'X'X\beta$$

Untuk mencapai nilai minimum, maka turunan parsial terhadap $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ sama dengan nol. Penurunan parsial terhadap β adalah sebagai berikut:

$$\begin{aligned} \frac{\partial(\varepsilon' \varepsilon)}{\partial \beta} &= 0 \\ -2X'Y + 2X'X\hat{\beta} &= 0 \\ X'X\hat{\beta} &= X'Y \\ \hat{\beta} &= (X'X)^{-1}X'Y \end{aligned}$$

2.3.3 Pengujian Parameter Regresi Linear Berganda

1. Pengujian Parameter secara Serentak (Simultan)

Menurut Hines dan Montgomery (1990) uji simultan digunakan untuk menentukan apakah ada hubungan linier antara peubah respon dan peubah prediktor. Hipotesis dalam uji simultan adalah sebagai berikut:

- Hipotesis yang diuji adalah sebagai berikut:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$

$$H_1: \text{minimal terdapat satu } \beta_k \neq 0; k = 1, 2, \dots, p$$

- Taraf Signifikansi:

Tingkat signifikansi (α) yang seringkali digunakan dalam penelitian adalah 5%.

- Statistik Uji:

Tabel Anova

Sumber variansi	Derajat Bebas	Jumlah Kuadrat	Kuadrat Tengah	Statistik uji
Regresi	p	JKR $= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	$KTR = \frac{SSR}{p}$	$F = \frac{KTR}{KTG}$
Galat	n-p-1	JKG $= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	KTG $= \frac{SSE}{n - p - 1}$	
Total	n-1	JKT $= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$		

- Kriteria Menolak H_0 :

$$H_0 \text{ ditolak jika } F > F(\alpha, p, n - p - 1) \text{ atau jika } p - \text{value} < \alpha.$$

2. Pengujian Parameter secara Individu (Parsial)

Uji parsial atau yang sering disebut juga pengujian parameter regresi secara individu dilakukan untuk mengetahui parameter mana saja yang berpengaruh secara signifikan terhadap variabel respon.

- Hipotesis yang diuji adalah sebagai berikut:

$$H_0: \beta_j = 0$$

$$H_1: \beta_j \neq 0$$

- Taraf Signifikansi:

Tingkat signifikansi (α) yang seringkali digunakan dalam penelitian adalah 5%.

- Statistik Uji:

$$t = \frac{\widehat{\beta}_k}{\sqrt{\frac{KTG}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

- Kriteria Menolak H_0 :

H_0 ditolak jika $|t| > t_{\alpha^2, n-p-1}$ atau $p - value < \alpha$

2.3.4 Pengujian Asumsi Regresi Linear Berganda

1. Uji Normalitas Galat

Analisis regresi linier dikatakan baik apabila galat menyebar secara normal. Galat dapat dikatakan menyebar normal apabila memiliki nilai tengah 0 dan ragam σ^2 (Gujarati, 2006). Pengujian asumsi galat berdistribusi normal dengan mean nol dilakukan dengan uji *Kolmogorov-Smirnov*. Uji *Kolmogorov-Smirnov* digunakan untuk menguji apakah dua buah distribusi data dapat dikatakan berbeda secara signifikan. Pada penelitian ini galat pada pemodelan regresi linier berganda akan dibandingkan dengan sebuah data berdistribusi normal dengan mean nol yang dibangun oleh *software R*.

- Hipotesis:

H_0 : Galat berdistribusi normal dengan mean 0

H_1 : Galat tidak berdistribusi normal dengan mean 0

- Statistik Uji:

$$D = \text{Sup}_x [|F_n(x) - F_0(x)|]$$

Sup_x = Supremum himpunan jarak antara $F_n(x)$ dan $F_0(x)$

$F_n(x)$ = Nilai fungsi distribusi kumulatif pada distribusi normal di titik x .

$F_0(x)$ = Nilai fungsi distribusi kumulatif empiris di titik x .

- Kriteria Menolak H_0 :

$$D > D_{\alpha,n} \text{ atau } p\text{-value} < 0,05$$

2. Uji Autokorelasi

Autokorelasi adalah terjadinya korelasi antara satu variabel *error* dengan variabel *error* yang lain. Selanjutnya untuk mendeteksi adanya autokorelasi dalam model regresi linier berganda dapat digunakan metode Durbin-Watson. Durbin-Watson telah berhasil mengembangkan suatu metode yang digunakan untuk mendeteksi adanya masalah autokorelasi dalam model regresi linier berganda.

- Hipotesis:

H_0 : Tidak terdapat autokorelasi

H_1 : Terdapat autokorelasi

- Taraf Signifikansi:

$$\alpha = 0.05$$

- Statistik Uji:

$$d = \frac{\sum_{i=2}^n (\varepsilon_i - \varepsilon_{i-1})^2}{\sum_{i=2}^n \varepsilon_i^2}$$

- Kriteria menolak H_0 :


Ketentuan untuk mengambil keputusan uji Durbin-Watson adalah:

- Tolak H_0 jika $d < d_L$ atau $d > 4 - d_L$, sehingga terdapat autokorelasi antar galat.
- Terima H_0 jika $d < d_U$ atau $d < 4 - d_U$, sehingga tidak terdapat autokorelasi antar galat.
- Tidak dapat mengambil keputusan jika $d_L \leq d \leq d_U$ atau $4 - d_U \leq d \leq 4 - d_L$.


3. Uji Homoskedastisitas

Salah satu asumsi dalam analisis regresi linier adalah variansi galat bersifat konstan (homoskedastisitas). Untuk mengujinya dapat dilakukan plot antara nilai \hat{y} dan galat ε .

- Jika hasil plot menyebar dengan acak menyerupai gambar di bawah, maka dapat disimpulkan asumsi homoskedastisitas terpenuhi.



- Jika hasil plot membentuk corong menyerupai gambar di bawah, maka dapat disimpulkan asumsi homoskedastisitas tidak terpenuhi.



4. Uji Multikolinearitas

Multikolinieritas adalah terjadinya hubungan linier antara variabel bebas dalam suatu model regresi linier berganda. Apabila multikolinieritas terjadi, meskipun penduga dari metode kuadrat terkecil bisa diperoleh tetapi *standard error* cenderung semakin besar dengan semakin besar tingkat korelasi antar peubah prediktor. Sehingga pendugaan parameter tidak akurat.

Adanya hubungan linier yang kuat antar peubah bebas (multikolinearitas) dilihat dari nilai *Variance Inflating Factor* (VIF). Nilai VIF dihitung dengan rumus berikut.

$$VIF = \frac{1}{(1 - R_k^2)}$$

dengan R_k^2 adalah nilai koefisien determinasi ketika peubah bebas X_k diregresikan dengan peubah bebas yang lain. Jika nilai VIF lebih dari 10 maka dapat disimpulkan terdapat multikolinearitas antar peubah.

2.4 *Geographically Weighted Regression (GWR)*

Asumsi yang diuji pada tahap pendugaan parameter model regresi linier berganda adalah asumsi galat berdistribusi normal, tidak terjadi autokorelasi, tidak terjadi multikolinearitas, dan tidak terjadi heteroskedastisitas. Jika seluruh asumsi regresi linier berganda terpenuhi maka model regresi linier berganda digunakan untuk menganalisis data penelitian. Jika terdeteksi terdapat efek heterogenitas spasial maka analisis data menggunakan metode *Geographically Weighted Regression (GWR)*.

Terdapat dua model GWR yang akan dibandingkan pada penelitian ini yaitu model GWR dengan fungsi pembobot Kernel Gaussian dan model GWR dengan fungsi pembobot Kernel Bisquare. Kedua model tersebut akan dibandingkan berdasarkan skor AIC dan koefisien determinasi (R^2) untuk mendapatkan model terbaik. Model terbaik yang telah didapatkan, selanjutnya akan dianalisis signifikansi dugaan parameternya dan dilakukan interpretasi sebaran dugaan parameter menggunakan peta.

2.4.1 Pengujian Pengaruh Spasial

Pengujian heterogenitas spasial dilakukan dengan menggunakan statistik uji Breusch Pagam (BP).

- Hipotesis:

$$H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_{24}^2 = \sigma^2 \text{ (tidak terdapat heterogenitas spasial)}$$

$$H_1: \text{Terdapat paling sedikit satu } \sigma_i^2 \neq \sigma^2, i = 1, 2, \dots, 24 \text{ (ada heterogenitas spasial)}$$

- Statistik Uji:

$$BP = \left(\frac{1}{2}\right) \mathbf{f}' \mathbf{Z} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{f} .$$

$$\text{Elemen vektor } \mathbf{f} \text{ dirumuskan } f_i = \frac{e_i^2}{\sigma^2} - 1$$

- Kriteria menolak H_0 :

$$BP > \chi_{\alpha, p}^2$$

2.4.2 Model *Geographically Weighted Regression (GWR)*

Model *Geographically Weighted Regression (GWR)* dapat ditulis sebagai berikut:

$$Y_i = \beta_0(u_i, v_i) + \sum_{k=1}^p \beta_k(u_i, v_i) X_{ik} + \varepsilon_i, i = 1, 2, \dots, n$$

Keterangan:

Y_i	= nilai variabel respon pada titik lokasi pengamatan ke- i
X_{ik}	= nilai variabel prediktor ke- k pada titik lokasi pengamatan ke- i
(u_i, v_i)	= koordinat titik lokasi pengamatan ke- i (longitude, latitude)
$\beta_0(u_i, v_i)$	= koordinat/intercept GWR
$\beta_k(u_i, v_i)$	= koefisien regresi ke- k pada titik lokasi pengamatan ke- i
ε_i	= <i>error</i> pada titik lokasi ke- i yang diasumsikan dengan rata-rata 0 dan varians σ^2

2.4.3 Pendugaan Parameter Model *Geographically Weighted Regression* (GWR)

Pengestimasian parameter $\beta(u_i, v_i)$ pada lokasi ke- i , dapat dilakukan dengan menggunakan metode *Weighted Least Squares* atau WLS (Brunsdon et al., 1996). Dalam pengestimasian parameter di suatu titik lokasi, metode WLS memberikan pembobot yang tidak sama pada semua amatan. Besarnya pembobot tersebut didasarkan pada jarak antar lokasi amatan. Semakin dekat jarak terhadap amatan yang diestimasi parameternya, semakin besar bobot tersebut dalam estimasi $\beta(u_i, v_i)$.

Pendugaan parameter WLS yang meminimumkan jumlah kuadrat galat dengan menambahkan pembobot untuk setiap lokasi pengamatan (u_i, v_i) . Diperoleh estimator parameter model GWR sebagai berikut:

$$\hat{\beta}(u_i, v_i) = [X'W(u_i, v_i)X]^{-1}X'W(u_i, v_i)Y$$

di mana $W_i = \text{diag}[w_1(u_i, v_i), w_2(u_i, v_i), \dots, w_n(u_i, v_i)]$ adalah diagonal pembobot yang bervariasi dari setiap prediksi parameter pada lokasi i .

2.4.4 Fungsi Pembobot Spasial

Peran pembobot dalam GWR merupakan aspek penting. Pembobot tersebut bergantung pada jarak antar titik lokasi pengamatan. Pembobot berupa matriks diagonal dimana elemen-elemen diagonalnya merupakan sebuah fungsi pembobot dari setiap titik lokasi pengamatan. Fungsi dari matriks pembobot adalah untuk menentukan atau menaksir parameter yang berbeda pada setiap titik lokasi pengamatan. Salah satu metode pembobotan yang biasa digunakan adalah Kernel Gaussian dan Kernel Bisquare.

- Fungsi Kernel Gaussian

$$K_G(d_{ij}) = e^{\left[-\frac{1}{2}\left(\frac{d_{ij}}{b}\right)^2\right]}$$

- Fungsi Kernel Bisquare

$$K_B(d_{ij}) = \begin{cases} \left[1 - \frac{1}{2}\left(\frac{d_{ij}}{b}\right)^2\right]^2, & \text{jika } d_{ij} < b \\ 0, & \text{lainnya} \end{cases}$$

dimana d_{ij} adalah jarak *eucliden* antara lokasi (u_i, v_i) ke lokasi (u_j, v_j) dan h adalah parameter non negatif yang biasanya disebut parameter penghalus (*bandwidth*).

$$d_{ij} = \sqrt{(u_i - u_j)^2 + (v_i - v_j)^2}$$

2.4.5 Penentuan *Bandwidth* Minimum

Metode yang digunakan untuk memilih *bandwidth* optimum adalah metode validasi silang atau *cross validation* (CV). *Cross Validation* (CV) adalah metode untuk mengevaluasi model-model regresi dengan suatu ukuran kemampuan prediksi dan memilih satu model yang terbaik. *Bandwidth* optimum adalah *bandwidth* yang menghasilkan CV minimum. Nilai penduga y_i dari model GWR dinyatakan:

$$\hat{y} = \mathbf{x}'\hat{\boldsymbol{\beta}}(u_i, v_i) = \mathbf{x}'[\mathbf{X}'\mathbf{W}(u_i, v_i)\mathbf{X}]^{-1}\mathbf{X}'\mathbf{W}(u_i, v_i)\mathbf{y}$$

dengan $\mathbf{x}'_i = (1, x_{i1}, x_{i2}, \dots, x_{ip})$ merupakan elemen baris ke- i dari matriks \mathbf{X} . Apabila nilai-nilai penduga y_i seperti pada persamaan di atas merupakan fungsi dari *bandwidth* (h) ditulis $\hat{y}_i(h)$. Maka nilai *bandwidth* dengan metode CV diperoleh dengan menghilangkan observasi ke- i dalam menduga nilai y_i pada model. Secara matematis CV dapat dituliskan sebagai berikut:

$$CV(h) = \sum_{i=1}^n (y_i - \hat{y}_i(h))^2$$

2.4.6 Uji Parameter Model *Geographically Weighted Regression* (GWR)

Setelah melakukan uji kesesuaian model, dilakukan pengujian parameter model. Pengujian parameter model GWR dilakukan dengan menguji parameter secara parsial. Pengujian dilakukan untuk mengetahui parameter mana saja yang signifikan mempengaruhi variabel responnya. Bentuk hipotesisnya adalah sebagai berikut :

- Hipotesis:

$H_0: \beta_k(u_i, v_i) = 0$ (tidak terdapat satu variabel bebas terhadap variabel tak bebas)

$H_1: \beta_k(u_i, v_i) \neq 0, k = 1, 2, \dots, p$ (minimal terdapat satu variabel bebas yang berpengaruh terhadap variabel tak bebas)

- Statistik Uji:

$$t_{hit} = \frac{\hat{\beta}_k(u_i, v_i)}{SE[\hat{\beta}_k(u_i, v_i)]}$$

- Kriteria menolak H_0 :

$|t_{hit}| > t_{1-\frac{\alpha}{2};(n-p-1)}$ (diperoleh dari Tabel Distribusi t-Student dengan taraf signifikansi 5%)

2.4.7 Penentuan Model Terbaik

Pada penelitian ini, model GWR dengan fungsi pembobot spasial Kernel Gaussian dan Kernel Bisquare akan dibandingkan menurut koefisien determinasi (R^2) dan skor AIC.

- a. Koefisien Determinasi (R^2)

Koefisien determinasi adalah suatu ukuran variasi peubah terikat yang dapat diprediksi oleh peubah bebas. Semakin besar skor R^2 suatu model maka model dianggap semakin baik. Koefisien determinasi dihitung dengan rumus sebagai berikut.

$$R^2 = 1 - \frac{JKG}{JKT}$$

Keterangan:

JKG : Jumlah kuadrat galat ($JKG = \sum_{i=1}^n \hat{\epsilon}_i^2$)

JKT : Jumlah kuadrat total ($JKT = \sum_{i=1}^n (y_i - \bar{y})^2$)

b. *Akaike Information Criterion (AIC)*

AIC adalah sebuah ukuran relatif kualitas suatu model statistik terhadap model statistik lain. Model dengan skor AIC lebih kecil dianggap sebagai model yang lebih baik. Skor AIC suatu model dihitung dengan rumus sebagai berikut:

$$AIC = e^{\frac{2k}{n} \sum_{i=1}^n \hat{\epsilon}_i^2}$$

Keterangan:

k : Jumlah parameter

n : Jumlah observasi

$\hat{\epsilon}_i$: Galat pada observasi ke- i

2.5 Langkah-langkah Analisis dalam Regresi dan *Geographically Weighted Regression (GWR)*

Adapun langkah-langkah analisis yang dilakukan dengan menggunakan *Geographically Weighted Regression (GWR)* adalah:

1. Mendeskripsikan variabel respon (Y) dan variabel-variabel prediktor (X) yang akan dilibatkan dalam pembentukan model regresi.
2. Menganalisis model regresi linear klasik atau *Ordinary Linear Regression (OLR)* dengan langkah-langkah sebagai berikut:
 - Melakukan uji asumsi residual atau asumsi regresi linear klasik (normalitas, multikolinearitas, heteroskedastisitas, autokorelasi)
 - Menaksir parameter model regresi linear klasik dengan metode kuadrat terkecil atau *Ordinary Least Square (OLS)*
 - Melakukan uji signifikansi parameter, uji serentak dan uji individu
3. Menganalisis model *Geographically Weighted Regression (GWR)* dengan langkah-langkah sebagai berikut:
 - Menentukan koordinat *longitude-latitude* tiap titik wilayah pengamatan
 - Menghitung jarak Euclidean antara lokasi i terhadap lokasi j yang terletak pada koordinat (u_i, v_i)
 - Menentukan *bandwidth* salah satunya berdasarkan kriteria CV minimum
 - Menghitung matriks pembobot (W_{ij}) tiap titik wilayah pengamatan dengan fungsi Kernel, Kernel Gaussian dan Kernel Bisquare
 - Menaksir parameter GWR dengan menggunakan WLS

- Melakukan pengujian kesamaan model regresi linear dan GWR
 - Melakukan pengujian signifikansi parameter model GWR
4. Menentukan model terbaik menggunakan Koefisien Determinasi (R^2) dan AIC untuk model GWR dengan pembobot Kernel Gaussian Kernel Bisquare.
 5. Menginterpretasi dan menyimpulkan hasil yang diperoleh.

BAB 3

DATA

3.1 Sumber Data

Data yang digunakan pada penelitian adalah data sekunder, yaitu data Indeks Pembangunan Manusia (IPM) dan faktor-faktor yang memengaruhinya di Provinsi Jawa Barat tahun 2021. Data diperoleh dari *website* Badan Pusat Statistik (BPS) Provinsi Jawa Barat.

3.2 Variabel Penelitian

Tabel 1. Nama dan Penjelasan Variabel

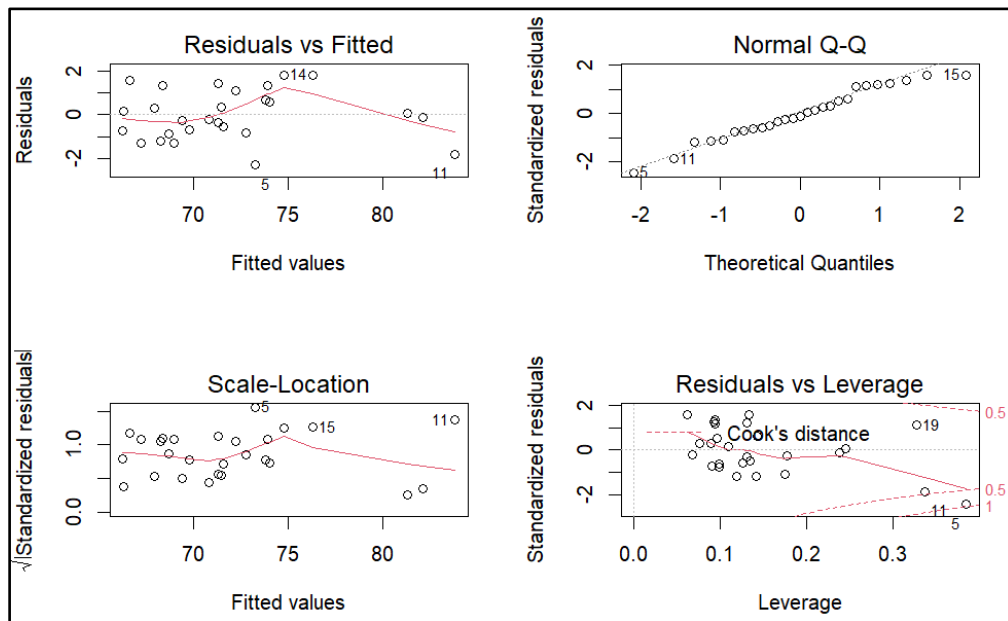
Variabel	Nama Variabel	Definisi
Y	Indeks Pembangunan Manusia	IPM adalah angka yang mewakili kondisi penduduk dalam mengakses hasil pembangunan, memperoleh pendapatan, mengakses kesehatan, pendidikan, dan sejumlah aspek lain.
X_1	Pendapatan per Kapita	Pendapatan Per Kapita adalah ukuran jumlah uang yang diperoleh per orang di suatu negara atau wilayah geografis. Pendapatan per kapita dapat digunakan untuk menentukan pendapatan rata-rata per orang untuk suatu daerah dan untuk mengevaluasi standar hidup dan kualitas hidup penduduk.
X_2	Harapan Lama Sekolah	Angka Harapan Lama Sekolah didefinisikan sebagai lamanya sekolah (dalam tahun) yang diharapkan akan dirasakan oleh anak pada umur tertentu di masa mendatang.
X_3	Persentase Penduduk Miskin	Persentase Penduduk Miskin adalah persentase penduduk yang berada dibawah garis kemiskinan. Garis kemiskinan itu sendiri mencerminkan nilai rupiah pengeluaran minimum yang diperlukan seseorang untuk memenuhi kebutuhan pokok hidupnya selama sebulan, baik kebutuhan makanan maupun non-makanan.

BAB 4

ANALISIS DATA

4.1 Uji Asumsi

Pertama, akan dilakukan uji asumsi untuk model regresi. Asumsi yang harus dipenuhi adalah asumsi normalitas, heteroskedastisitas, multikolinieritas, dan autokorelasi. Dengan menggunakan *software* Rstudio, akan ditampilkan grafik mengenai uji asumsi residual dari data yang dimiliki sebagai berikut:



Gambar 1. Grafik Uji Asumsi

Uji Asumsi Normalitas

Pengujian asumsi normalitas akan dilakukan dengan metode uji Kolmogorov-Smirnov dengan menggunakan *software* Rstudio.

- Tujuan

Untuk mengetahui apakah residual/error terstandarisasi yang diteliti berdistribusi normal atau tidak.

- Hipotesis

H_0 = residual/error berdistribusi normal

H_1 = residual/error tidak berdistribusi normal

- Tingkat Signifikansi

$\alpha = 0,05$

- Statistik Pengujian

Dengan menggunakan uji Kolmogorov-Smirnov dengan *software* Rstudio, diperoleh

```
> ### Asumsi Normalitas: Uji Kolmogorov-Smirnov ###
> mod.er=residuals(mod)
> ks.test(mod.er,'pnorm')

One-sample Kolmogorov-Smirnov test


data:  mod.er
D = 0.13348, p-value = 0.673
alternative hypothesis: two-sided
```

Diperoleh

$$D = 0.13348$$

$$p - value = 0.673$$

Scatter plot dari Uji Normalitas:



Gambar 2. Plot Uji Normalitas

- Aturan Keputusan

H_0 ditolak jika $p - value < \alpha$

Karena $p - value = 0.673 > 0.05 = \alpha$, maka H_0 tidak ditolak

- Kesimpulan

Jadi, pada $\alpha = 0.05$ diperoleh bahwa H_0 tidak ditolak. Dapat disimpulkan bahwa residual berdistribusi normal. Jadi, uji asumsi Normalitas terpenuhi.

Uji Asumsi Homogenitas (Heteroskedastisitas)

Pengujian asumsi heteroskedastisitas akan dilakukan dengan uji *Breusch Pagan Test* dengan menggunakan *software* Rstudio.

- Tujuan
Untuk mengetahui apakah residual/error terdapat kesamaan variansi atau tidak.
- Hipotesis
 H_0 : tidak terdapat gejala heteroskedastisitas
 H_1 : terdapat gejala heteroskedastisitas
- Tingkat signifikansi
 $\alpha = 0,05$
- Statistik Pengujian

Dengan menggunakan uji *Breusch Pagan* dengan *software* Rstudio, diperoleh


```
> ### Asumsi Heteroskedastisitas: Uji Breusch Pagan ###  
> library("quantmod")  
> library("lmtest")  
> bptest(mod)  
  
studentized Breusch-Pagan test  
  
data: mod  
BP = 8.522, df = 3, p-value = 0.03637
```

Diperoleh

$BP = 8.522$

$p - value = 0.03637$

Scatter plot dari Uji Heteroskedastisitas:



Gambar 3. Scatter Plot Uji Heteroskedastisitas

- Aturan Keputusan
 H_0 ditolak jika $p - value < \alpha$
 Karena $p - value = 0.03637 < 0.05 = \alpha$, maka H_0 ditolak
- Kesimpulan
 Jadi, pada $\alpha = 0.05$ diperoleh bahwa H_0 ditolak. Dapat disimpulkan bahwa variansi residual terdapat gejala heteroskedastisitas.

Uji Multikolinieritas

Akan diperiksa multikolinearitas dengan menggunakan nilai VIF dari ketiga variabel independen. Didapatkan *output* sebagai berikut:

- Tujuan
 Untuk mengetahui apakah ada korelasi yang kuat antara 2 variabel independen.
- Hipotesis
 H_0 : Terjadi multikolinearitas pada model
 H_1 : Tidak terjadi multikolinearitas pada model
- Taraf Signifikansi
 $\alpha = 0.05$
- Statistik Pengujian

Dengan menggunakan uji *VIF* dengan *software* Rstudio, diperoleh

```
> ### Asumsi Multikolinieritas: Uji VIF ###
> # Uji Multikolinearitas
> vif(mod)
      x1      x2      x3
2.395596 2.017328 2.339145
```

- Aturan Keputusan:
 H_0 ditolak jika $VIF < 10$
 Diperoleh
 - Untuk variabel x_1
 Nilai $VIF = 2.395596 < 10$
 - Untuk variabel x_2
 Nilai $VIF = 2.017328 < 10$
 - Untuk variabel x_3
 Nilai $VIF = 2.339145 < 10$

- Kesimpulan

Dengan $\alpha = 0,05$ diperoleh $VIF < 10$, sehingga H_0 ditolak. Dapat disimpulkan bahwa tidak terjadi multikolinieritas pada data. Jadi, asumsi multikolinieritas terpenuhi.

Uji Autokorelasi

Pengujian asumsi autokorelasi akan dilakukan dengan metode uji *Durbin-Watson* dengan menggunakan *software* Rstudio.

- Tujuan

Untuk mengetahui apakah residual/error terstandarisasi yang diteliti terdapat autokorelasi/tidak.

- Hipotesis

H_0 : tidak terdapat autokorelasi

H_1 : terdapat autokorelasi

- Taraf Signifikansi

$\alpha = 0.05$

- Statistik Pengujian

Dengan menggunakan uji Durbin-Watson dengan *software* Rstudio, diperoleh

```
> ### Asumsi Autokorelasi : Uji Durbin Watson ###
> dwtest(Y~X1+X2+X3,data=ipm_jabar)

Durbin-Watson test

data: Y ~ X1 + X2 + X3
DW = 1.0561, p-value = 0.002113
alternative hypothesis: true autocorrelation is greater than 0
```

- Aturan Keputusan

H_0 ditolak jika $p - value < \alpha$

Karena $p - value = 0.002113 < 0.05 = \alpha$, maka H_0 ditolak

- Kesimpulan

Jadi, pada $\alpha = 0.05$ diperoleh bahwa H_0 ditolak. Dapat disimpulkan bahwa terdapat autokorelasi diantara residual.

4.2 Analisis Regresi Global

Pemodelan dan pendugaan parameter regresi global dilakukan dengan metode *ordinary least square* dengan Indeks Pembangunan Manusia (IPM) sebagai variabel dependen dan Pendapatan per Kapita, Rata-rata Lama Sekolah, dan Angka Harapan Hidup sebagai variabel independen. Dengan menggunakan *software* Rstudio diperoleh:

```
> mod<-lm(Y~X1+X2+X3,data=ipm_jabar)
> summary(mod)

Call:
lm(formula = Y ~ X1 + X2 + X3, data = ipm_jabar)

Residuals:
    Min       1Q   Median       3Q      Max
-2.3174 -0.7692 -0.1250  0.8877  1.8290

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 29.6106204  5.7780215   5.125 3.43e-05 ***
X1           0.0013073  0.0001612   8.112 3.38e-08 ***
X2           2.2849043  0.4266778   5.355 1.94e-05 ***
X3          -0.1146074  0.1254520  -0.914  0.37
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.21 on 23 degrees of freedom
Multiple R-squared:  0.9434,    Adjusted R-squared:  0.936
F-statistic: 127.7 on 3 and 23 DF,  p-value: 1.753e-14
```

Sehingga, model regresi yang terbentuk adalah:

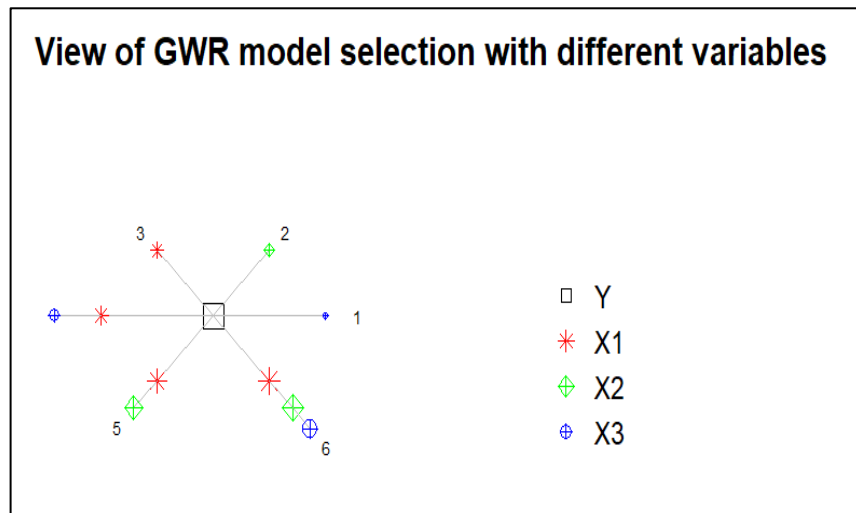
$$\hat{y} = 29.6106204 + 0.0013073X_1 + 2.2849043X_2 - 0.1146074X_3$$

Dari *output* di atas diperoleh $p - value = 1.753e - 14 < 0.05 = \alpha$, sehingga dapat disimpulkan bahwa pada keseluruhan model setidaknya ada satu variabel independen yang signifikan. Pada *output* di atas dapat dilihat bahwa terdapat dua variabel independen signifikan. Berdasarkan pengujian hipotesis, diperoleh bahwa terdapat dua variabel independent yang signifikan memengaruhi IPM, yaitu Pendapatan per Kapita dan Rata-rata Lama Sekolah


4.3 Analisis Geographically Weighted Regression (GWR)

4.3.1 Pemilihan Peubah Bebas

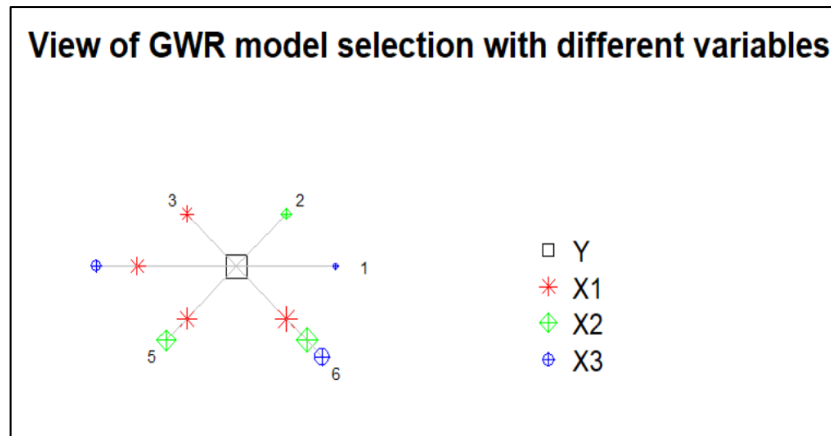
Pada GWR, metode yang digunakan pada pemilihan peubah bebas adalah *pseudo-stepwise*. Ilustrasi langkah-langkah *pseudo-stepwise* adalah sebagai berikut:




Gambar 4. *Pseudo-Stepwise* Kernel Gaussian



Gambar 5. Langkah *Pseudo-Stepwise* Kernel Gaussian



Gambar 6. *Pseudo-Stepwise* Kernel Bisquare



Gambar 7. Langkah *Pseudo-Stepwise* Kernel Bisquare

Pada gambar di atas terlihat bahwa proses *pseudo-stepwise* berjalan dalam 6 langkah dari dilibatkannya satu peubah hingga dilibatkannya tiga peubah. Dalam grafik diatas ditemukan CV untuk kernel gaussian dan kernel bisquare fluktuatif dengan langkah ke 5 yang memiliki nilai terendah dan mendatar hingga langkah ke 6, sehingga akan dilakukan pemodelan GWR dengan melibatkan ketiga peubah bebas.

4.3.2 Penentuan *Bandwidth Optimum*

Langkah selanjutnya adalah menentukan nilai *bandwith optimum* yang digunakan sebagai parameter fungsi pembobot spasial.

Untuk fungsi Kernel Gaussian, *bandwith optimum* yang didapatkan adalah 2.394384, sehingga fungsi Kernel Gaussian yang digunakan untuk membuat matriks pembobot adalah

$$K_G(d_{ij}) = \exp \left[-\frac{1}{2} \left(\frac{d_{ij}}{0.3084612} \right)^2 \right]$$

Untuk fungsi pembobot Kernel Bisquare, *bandwith optimum* yang didapatkan adalah 2.4058, sehingga fungsi Kernel Bisquare yang digunakan untuk membuat matriks pembobot adalah

$$K_B(d_{ij}) = \left[1 - \frac{1}{2} \left(\frac{d_{ij}}{0.9201108} \right)^2 \right]^2$$

4.3.3 Pemilihan Model Terbaik

Untuk menentukan model terbaik, akan dibandingkan skor AIC dan *adjusted R²* dari masing-masing model. Berdasarkan *output* R Studio, didapatkan hasil:

Tabel 2. Skor AIC dan *Adjusted R²* Model

Model	AIC	<i>Adjusted R²</i>
Regresi Global	92.59596	0.936
GWR (Gaussian)	55.05187	0.9558549
GWR (Bisquare)	61.54554	0.9589804

Kriteria model terbaik adalah model dengan nilai AIC terkecil dan nilai *R-squared* terbesar. Berdasarkan tabel di atas, dapat dilihat bahwa model dengan AIC terkecil adalah model GWR dengan fungsi pembobot Kernel Gaussian. Selanjutnya, model dengan *R-squared* terbesar juga merupakan model GWR dengan fungsi pembobot Kernel Gaussian. Maka, dapat disimpulkan bahwa model terbaik untuk data penelitian adalah model GWR dengan fungsi pembobot Kernel Gaussian. Oleh karena itu, digunakan model GWR dengan fungsi pembobot Kernel Gaussian untuk proses analisis selanjutnya.

4.4 Peta *Geographically Weighted Regression* (GWR)

4.4.1 Sebaran Peubah Signifikan

Dengan metode GWR Kernel Bisquare, hanya terdapat satu kelompok lokasi yang terbentuk berdasarkan variabel independen pada data dengan tingkat signifikansi 5%. Kelompok untuk peubah signifikan adalah sebagai berikut:

Tabel 3. Kelompok Peubah Signifikan

Kel.	Peubah Sig.	Jumlah Kabupaten/Kota	Provinsi
1	$X_1, X_2,$ dan X_3	5	Kabupaten Bandung, Kota Bandung, Kota Cimahi, Kabupaten Subang, dan Kabupaten Sumedang
2	X_1 dan X_2	21	Kabupaten Bandung Barat, Kabupaten Bekasi, Kabupaten Bogor, Kabupaten Ciamis, Kabupaten Cianjur, Kabupaten Cirebon, Kabupaten Garut, Kabupaten Indramayu, Kabupaten Karawang, Kota Banjar, Kota Bekasi, Kota Bogor, Kota Cirebon, Kota Depok, Kota Sukabumi, Kota Tasikmalaya, Kabupaten Kuningan, Kabupaten Majalengka, Kabupaten Purwakarta, Kabupaten Sukabumi, dan Kabupaten Tasikmalaya
3	X_3	1	Kabupaten Pangandaran

Keterangan:

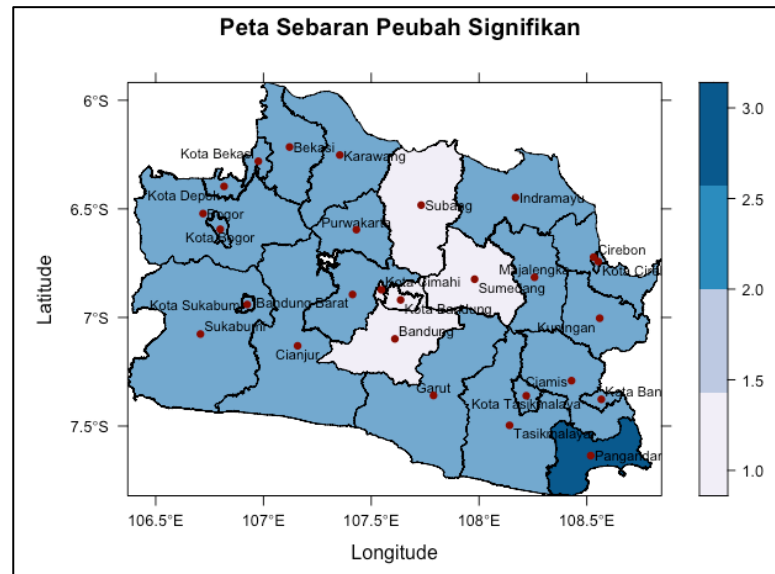
Y : Indeks Pembangunan Manusia

X_1 : Pendapatan per Kapita (Ribu/Rupiah/Orang/Tahun)

X_2 : Harapan Lama Sekolah

X_3 : Persentase Penduduk Miskin

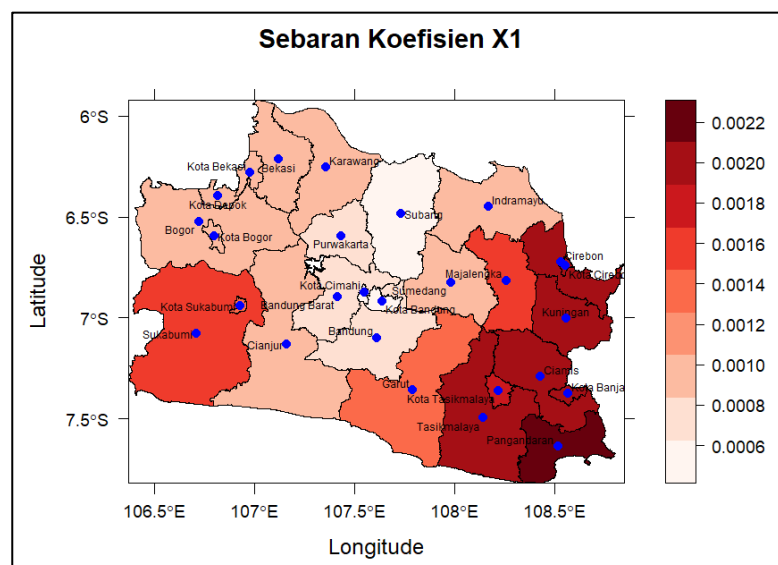
Visualisasi peta sebaran peubah signifikan yang terbentuk adalah sebagai berikut:



Gambar 8. Peta Sebaran Peubah Signifikan

Dari *output* peta pada Gambar 8 dan kelompok yang terbentuk dapat dilihat bahwa pada kelompok 3 memiliki variabel independen signifikan yang paling sedikit. Anggota dari kelompok 3 hanya Kabupaten Pangandaran. Hal tersebut menginterpretasikan bahwa pada Kabupaten Pangandaran, indeks pembangunan manusia hanya dipengaruhi oleh persentase penduduk miskin.

4.4.2 Keragaman Spasial Penduga Parameter β_1

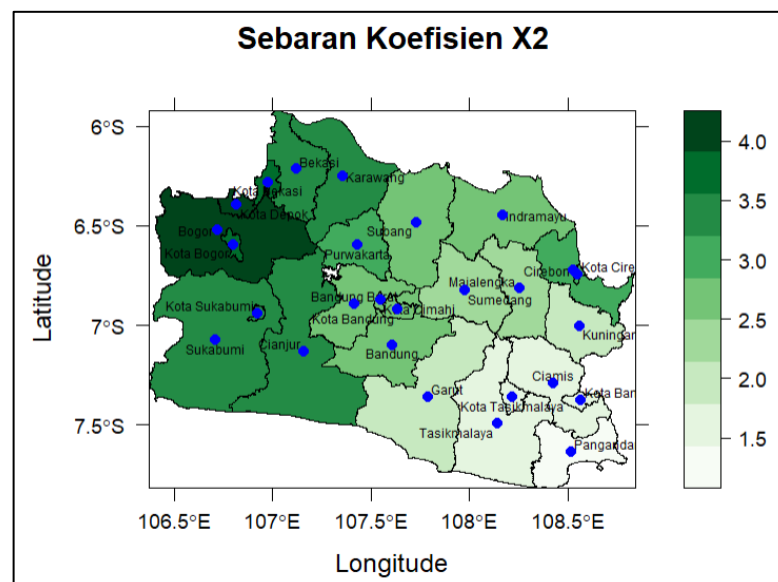


Gambar 9. Sebaran Koefisien Variabel Pendapatan Per Kapita

Gambar 9 menunjukkan visualisasi sebaran penduga parameter β_1 yang menggambarkan pengaruh pendapatan per kapita terhadap IPM di setiap daerah kabupaten/kota di Jawa Barat yang memperlihatkan bahwa penduga parameter nilainya bervariasi namun masing-masing kabupaten/kota yang berdekatan penduga parameternya hampir sama. Daerah berwarna gelap memiliki nilai penduga parameter lebih besar dan mengindikasikan pendapatan perkapita memiliki hubungan positif dengan IPM.

Pendapatan per kapita berpengaruh secara signifikan terhadap IPM daerah Jawa Barat di 26 kabupaten/kota yaitu Kab. Bandung, Kab. Bandung Barat, Kab. Bekasi, Kab. Bogor, Kab. Ciamis, Kab. Cianjur, Kab. Cirebon, Kab. Garut, Kab. Indramayu, Kab. Karawang, Kab. Kuningan, Kab. sMajalengka, Kab. Purwakarta, Kab. Subang, Kab. Sukabumi, Kab. Sumedang, Kab. Tasikmalaya, Kota Bandung, Kota Banjar, Kota Bekasi, Kota Bogor, Kota Cimahi, Kota Cirebon, Kota Depok, Kota Sukabumi, dan Kota Tasimalaya. Rentang nilai parameter untuk semua kabupaten/kota adalah 0.00052869 – 0.0022 atau dalam kata lain, setiap penambahan satu satuan pendapatan perkapita maka IPM akan meningkat sekitar 0.00052869 – 0.0022 satuan.

4.4.3 Keragaman Spasial Penduga Parameter β_2



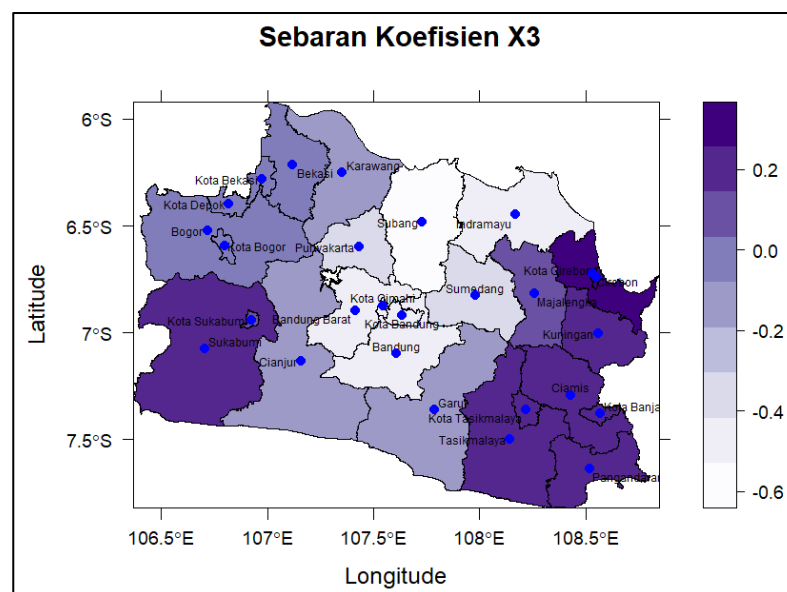
Gambar 10. Sebaran Koefisien Variabel Harapan Lama Sekolah

Gambar 10 menunjukkan sebaran nilai penduga parameter β_2 yang menggambarkan pengaruh harapan lama sekolah terhadap IPM di setiap daerah kabupaten/kota di Jawa Barat yang memperlihatkan bahwa penduga parameter hampir

sama di kabupaten/kota yang berdekatan. Daerah berwarna lebih gelap memiliki nilai penduga parameter lebih besar yang mengindikasikan harapan lama sekolah memiliki hubungan positif (berbanding lurus) dengan IPM.

Harapan lama sekolah berpengaruh secara signifikan terhadap IPM Jawa Barat di 26 kabupaten/kota, yaitu Kab. Bandung, Kab. Bandung Barat, Kab. Bekasi, Kab. Bogor, Kab. Ciamis, Kab. Cianjur, Kab. Cirebon, Kab. Garut, Kab. Indramayu, Kab. Karawang, Kab. Kuningan, Kab. Majalengka, Kab. Purwakarta, Kab. Subang, Kab. Sukabumi, Kab. Sumedang, Kab. Tasikmalaya, Kota Bandung, Kota Banjar, Kota Bekasi, Kota Bogor, Kota Cimahi, Kota Cirebon, Kota Depok, Kota Sukabumi, dan Kota Tasikmalaya. Rentang nilai parameter untuk ke-26 kabupaten/kota tersebut adalah 1.26899081 s.d. 4.0639 yang artinya setiap penambahan rata-rata lama sekolah maka IPM akan meningkat sekitar 1.26899081 s.d. 4.0639 satuan.

4.4.4 Keragaman Spasial Penduga Parameter β_3



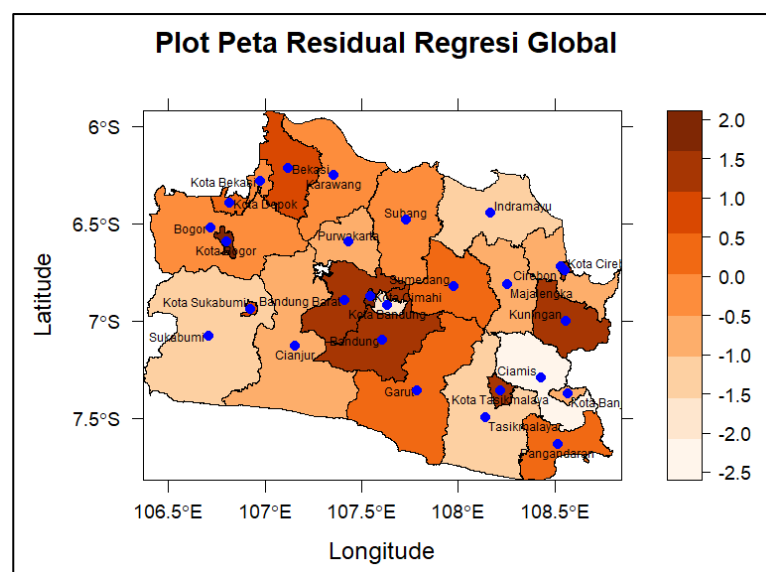
Gambar 11. Sebaran Koefisien Variabel Persentase Penduduk Miskin

Gambar 11 menunjukkan sebaran nilai penduga parameter β_3 yang menggambarkan pengaruh Persentase Penduduk Miskin terhadap IPM di setiap daerah kabupaten/kota di Jawa Barat yang memperlihatkan bahwa penduga parameter hampir sama di kabupaten/kota yang berdekatan. Daerah berwarna lebih gelap memiliki nilai penduga parameter lebih besar yang mengindikasikan angka harapan hidup memiliki hubungan positif (berbanding lurus) dengan IPM.

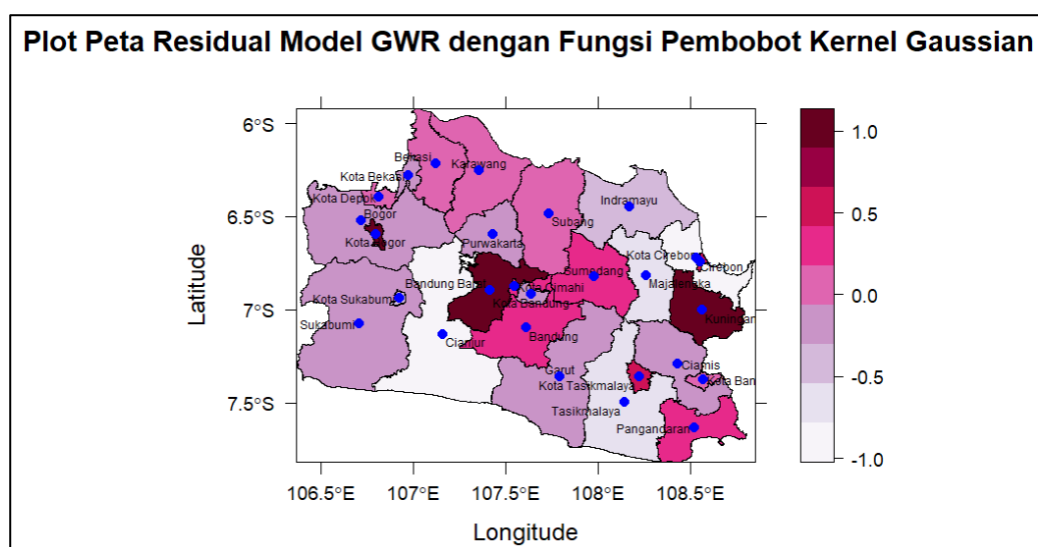
Angka Persentasi Penduduk Miskin berpengaruh secara signifikan terhadap IPM Jawa Barat di 6 kabupaten/kota yaitu, Kabupaten Bandung, Kota Bandung, Kota Cimahi, Kabupaten Subang, Kabupaten Pangandaran dan Kabupaten Sumedang. Rentang nilai parameter untuk ke-6 kabupaten/kota tersebut adalah -0.5801934 s.d 0.3063246 yang artinya setiap penambahan angka harapan hidup maka IPM akan meningkat sekitar -0.5801934 s.d 0.3063246 satuan.

4.4.5 Peta Residual

Selanjutnya akan ditampilkan nilai residual dalam peta.



Gambar 12. Plot Peta Residual Regresi Global



Gambar 13. Plot Peta Residual Model GWR dengan Fungsi Pembobot Kernel Gaussian

Dapat dilihat bahwa Gambar 12 menunjukkan residual pada peta dengan model regresi linier dan Gambar 13 menunjukkan residual pada peta model *Geographically Weighted Regression* (GWR) dengan fungsi pembobot spasial Kernel Gaussian. Sebelumnya, residual merupakan selisih dari nilai duga (*predicted value*) dan nilai sebenarnya (*actual*). Residual dikatakan baik apabila nilai residual mendekati nol, serta sebaliknya, residual dikatakan kurang baik apabila nilai residual menjauhi nol.

Berdasarkan Gambar 12 terlihat bahwa nilai maksimal residual yang ada mendekati angka 2.0, sedangkan pada Gambar 13 terlihat bahwa nilai maksimal residual yang ada mendekati angka 1.0. Karena residual pada peta model *Geographically Weighted Regression* (GWR) dengan fungsi pembobot spasial Kernel Gaussian lebih mendekati nol dibandingkan residual pada peta dengan model regresi linier maka dapat disimpulkan bahwa model *Geographically Weighted Regression* (GWR) dengan fungsi pembobot Kernel Gaussian lebih baik dibandingkan model regresi linier, maka dapat disimpulkan bahwa model *Geographically Weighted Regression* (GWR) dengan fungsi pembobot Kernel Gaussian lebih baik digunakan untuk menganalisis IPM Jawa Barat 2021 daripada model regresi linier.

BAB 5

PENUTUP

5.1 Kesimpulan

Metode *Geographically Weighted Regression* (GWR) dapat dilakukan ketika diketahui terjadi heterogenitas pada data. Analisis data menggunakan GWR diawali dengan melakukan pemilihan peubah bebas yang dilibatkan pada model GWR menggunakan metode *pseudo-stepwise*. Langkah berikutnya adalah menentukan *bandwidth* optimum sebagai parameter fungsi pembobot spasial. Selanjutnya, dilakukan pemilihan model terbaik yang dilakukan dengan menggunakan model GWR berdasarkan pembobot spasial Kernel Gaussian karena memberikan hasil yang terbaik dengan nilai AIC terkecil.

Selanjutnya dilakukan pendugaan parameter untuk tiap lokasi dan melakukan uji signifikansi parameter untuk mengetahui peubah bebas apa saja yang berpengaruh signifikan terhadap peubah terikat di suatu lokasi observasi. Langkah terakhir adalah membahas distribusi hasil pendugaan parameter model GWR.

Analisis hubungan IPM dengan faktor-faktor yang mempengaruhinya menggunakan metode *Geographically Weighted Regression* (GWR) menghasilkan nilai parameter model regresi yang berbeda di tiap kabupaten/kota di Jawa Barat. Faktor Pengeluaran per Kapita (PPK), Harapan Lama Sekolah (RLS), Persentase Penduduk Miskin (PPM), mempengaruhi secara signifikan terhadap IPM seluruh kabupaten/kota di Jawa Barat.

5.2 Saran

Jika terdapat heterogenitas pada data, lebih baik menggunakan model *Geographically Weighted Regression* (GWR) dibanding model *Ordinary Least Square* (OLS) karena memberikan hasil yang lebih baik.

Hasil penelitian ini dapat digunakan sebagai bahan pertimbangan bagi pemerintah daerah di Jawa Barat dalam upaya meningkatkan indeks pembangunan manusia sesuai dengan faktor-faktor yang signifikan di daerah tersebut.

DAFTAR PUSTAKA

- Badan Pusat Statistik Kabupaten Penajam Paser Utara. (n.d.). *Konsep Kemiskinan*.
<https://ppukab.bps.go.id/subject/23/kemiskinan.html>
- Badan Pusat Statistik. (n.d.). *Harapan Lama Sekolah (HLS)*.
<https://sirusa.bps.go.id/sirusa/index.php/indikator/1016>
- Badan Pusat Statistik. (n.d.). *Konsep Indeks Pembangunan Manusia*.
<https://www.bps.go.id/subject/26/indeks-pembangunan-manusia.html>
- Fauziyyah, Syifa. (2019). *Pengaruh Indeks Pembangunan Manusia Terhadap Pertumbuhan Ekonomi Provinsi Banten Periode Tahun 2010 – 2017* [Skripsi, Universitas Islam Negeri Serang Banten]. Universitas Islam Negeri Sultan Maulana Hasanuddin Banten Repository. <http://repository.uinbanten.ac.id/id/eprint/3812>

LAMPIRAN

Lampiran 1. Data IPM Jawa Barat

ID	Wilayah Jawa Barat	Lintang	Bujur	Y	X1	X2	X3
0	Kabupaten Bandung	-7.13407	107.621529	72.73	10,307.00	9.070	73.720
1	Kabupaten Bandung Barat	-6.90216	107.61911	68.2	8,546.00	8.200	72.520
2	Kabupaten Bekasi	-6.24331	106.99372	74.45	11,341.00	9.300	73.810
3	Kabupaten Bogor	-6.551776	106.629128	70.6	10,410.00	8.310	71.360
4	Kabupaten Ciamis	-7.332077	108.349251	70.93	9,259.00	7.900	72.020
5	Kabupaten Cianjur	-7.357977	107.195717	65.56	8,052.00	7.190	70.320
6	Kabupaten Cirebon	-6.71121	108.55924	69.12	10,368.00	7.100	72.180
7	Kabupaten Garut	-7.251216	107.923553	66.45	7,961.00	7.530	71.590
8	Kabupaten Indramayu	-6.352798	108.324341	67.64	9,810.00	6.520	71.840
9	Kabupaten Karawang	-6.32273	107.337578	70.94	11,522.00	7.780	72.330
10	Kabupaten Kuningan	-6.98101	108.492889	69.71	9,409.00	7.800	73.780
11	Kabupaten Majalengka	-6.83401	108.22763	67.81	9,591.00	7.310	70.460
12	Kabupaten Pangandaran	-7.8435	108.659538	68.28	9,065.00	7.850	71.600
13	Kabupaten Purwakarta	-6.540667	107.446274	70.98	11,669.00	8.100	71.180
14	Kabupaten Subang	-6.57128	107.75969	69.13	10,854.00	7.110	72.580
15	Kabupaten Sukabumi	-6.864924	106.953568	67.07	8,850.00	7.100	71.210
16	Kabupaten Sumedang	-6.832858	107.953186	71.8	10,262.00	8.520	72.620
17	Kabupaten Tasikmalaya	-7.3259	108.22093	65.9	7,829.00	7.480	69.670
18	Kota Bandung	-6.917464	107.619125	81.96	16,996.00	10.990	74.460
19	Kota Banjar	-7.36093	108.25	71.92	10,476.00	8.770	71.190
20	Kota Bekasi	-6.22414	106.99128	81.95	15,903.00	11.310	75.190
21	Kota Bogor	-6.597147	106.806038	76.59	11,716.00	10.530	73.820
22	Kota Cimahi	-6.884082	107.541306	78.06	12,019.00	11.080	74.210
23	Kota Cirebon	-6.76213	108.53281	75.25	11,810.00	10.120	72.440
24	Kota Depok	-6.402482	106.794243	81.37	15,420.00	11.460	74.620
25	Kota Sukabumi	-6.927736	106.929955	74.6	10,942.00	9.810	72.580
26	Kota Tasikmalaya	-7.30722	108.20179	73.31	10,213.00	9.520	72.340

Lampiran 2. Kode R

```
##### TUGAS 3: GWR (Geographically Weighted Regression) #####

### Import Packages ###
library(GWmodel)
library(car)
library(lmtest)
library(maptools)
library(RColorBrewer)
library(rgdal)
library(ggmap)
library(tidyr)
library(tmap)
library(rgeos)
library(foreign)
library(sp)
library(lattice)
library(classInt)
library(e1071)
library(shapefiles)

### Analisis Regresi Global ###
### Import Data ###
library(readxl)
Data <- read_excel("ipm_jabar.xlsx",
                   sheet = "Data GWR digeser")
View(Data)
head(Data)

### Describe Data ###
str(Data)
dim(Data)
names(Data)

### Define Variabel ###
Y = Data$IPM
X1 = Data$`Pengeluaran Per Kapita (Ribu Rupiah/Orang/Tahun)`
X2 = Data$`Harapan Lama Sekolah`
X3 = Data$`Persentase Penduduk Miskin`

### Model Regresi Global ###
mod <- lm(Y~X1+X2+X3, data=Data)
summary(mod)
names(mod)
resid <- data.frame(ID = c(0:26), mod$residuals)
resid
data.frame(resid$mod.residuals)

### Skor AIC ###
AIC(mod)

### UJI ASUMSI RESIDUAL ###
#Menampilkan plot
par(mfrow=c(2,2))
plot(mod)

#1. UJI ASUMSI NORMALITAS
#Uji Kolmogorov-Smirnov
mod.er=residuals(mod)
ks.test(rnorm(35, mean=0),mod.er)

#Menampilkan Normal Q-Q Plot
qqnorm(mod.er, ylab="Residuals", xlab="Normal Scores")
qqline(mod.er)
```

```

#2. UJI ASUMSI HETEROSKEDASTISITAS (Breusch Pagan Test)
#Uji Breusch Pagan (pake ini aja)
library("quantmod")
library("lmtest")
bptest(mod)
spreadLevelPlot(mod)

#3. UJI ASUMSI MULTIKOLONIERITAS
vif(mod)

#4. UJI AUTOKORELASI (Durbin Watson Test)
# Uji Durbin Watson (pake ini aja)
dwtest(Y~X1+X2+X3, data=Data)

### Mendapatkan matriks jarak antar lokasi observasi ###
Data.spdf <- SpatialPointsDataFrame(Data[,3:4],Data) #3 dan 4 adalah kolom Lintang
Bujur
head(Data.spdf)
m.jarak <- gw.dist(dp.locat=coordinates(Data.spdf))
m.jarak

### Metode Pseudo-stepwise ###
#Untuk model GWR dengan fungsi Kernel Gaussian
DeVar<-"Y"
InDeVars<-c("X1", "X2", "X3")
model.sel <- model.selection.gwr(DeVar, InDeVars, data=Data.spdf,
kernel="gaussian", adaptive=FALSE, bw=1, approach="CV", dMat=m.jarak)
model.sel
sorted.models<-model.sort.gwr(model.sel,numVars=length(InDeVars),
ruler.vector=model.sel[[2]][,2])
sorted.models
model.list <- sorted.models[[1]]
model.list
model.view.gwr(DeVar, InDeVars, model.list=model.list)
plot(sorted.models[[2]][,2],col="black", pch=20, lty=5,
      main = "Alternative view of GWR model selection procedure",
      ylab = "CV",
      xlab = "Model number", type = "b")

### Untuk model GWR dengan fungsi Kernel Bisquare ###
DeVar <- "Y"
InDeVars<-c("X1", "X2", "X3")
model.sel<-model.selection.gwr(DeVar, InDeVars, data=Data.spdf, kernel="gaussian",
adaptive=FALSE, bw=1, approach="CV", dMat=m.jarak)
model.sel
sorted.models<-model.sort.gwr(model.sel,numVars=length(InDeVars),
ruler.vector=model.sel[[2]][,2])
sorted.models
model.list<-sorted.models[[1]]
model.list
model.view.gwr(DeVar, InDeVars, model.list=model.list)
plot(sorted.models[[2]][,2],col="black", pch=20, lty=5,
      main = "Alternative view of GWR model selection procedure",
      ylab = "CV",
      xlab = "Model number", type = "b")

### Menentukan bandwidth optimum menggunakan CV (Cross Validation) ###
#Untuk model GWR dengan fungsi Kernel Gaussian
bw.mod.gwr.gauss<-bw.gwr(Y~X1+X2+X3 , data=Data.spdf,
                        approach="CV",
                        kernel="gaussian",
                        adaptive=F)
bw.mod.gwr.gauss

#Untuk model GWR dengan fungsi Kernel Bisquare
bw.mod.gwr.bisq<-bw.gwr(Y~X1+X2+X3, data=Data.spdf,
                      approach="CV",
                      kernel="bisquare",

```



```

                                adaptive=F)
bw.mod.gwr.bisq

### Melakukan estimasi parameter model GWR (Pemilihan Model Terbaik) ###
#Untuk model GWR dengan fungsi Kernel Gaussian
gwr.gaus<-gwr.basic(Y~X1+X2+X3, data=Data.spdf,
                    bw=bw.mod.gwr.gauss,
                    kernel="gaussian",
                    adaptive=F)

print(gwr.gaus)
summary(gwr.gaus)

### Untuk model GWR dengan fungsi Kernel Bisquare ###
gwr.bisq<-gwr.basic(Y~X1+X2+X3, data=Data.spdf,
                    bw=bw.mod.gwr.bisq,
                    kernel="bisquare",
                    adaptive=F)

print(gwr.bisq)
summary(gwr.bisq)

### Data untuk Peta2an ###
df.int <- data.frame(ID = c(0:26), gwr.gaus$SDF$Intercept)
df.x1 <- data.frame(ID = c(0:26), gwr.gaus$SDF$X1)
df.x2 <- data.frame(ID = c(0:26), gwr.gaus$SDF$X2)
df.x3 <- data.frame(ID = c(0:26), gwr.gaus$SDF$X3)
df.res <- data.frame(ID = c(0:26), gwr.gaus$SDF$residual)
df.studres <- data.frame(ID = c(0:26), gwr.gaus$SDF$Stud_residual)

### Melakukan uji signifikansi parameter GWR ###
gwr.t.adjust(gwr.gaus) #pake ini karena model terbaik
gwr.t.adjust(gwr.bisq)

sign <- gwr.t.adjust(gwr.bisq)
df.beta <- data.frame(sign$results$t)
df.beta

#####
##### Peta #####
### Import Packages ###
library(maptools)
library(RColorBrewer)
library(sp)
library(foreign)
library(lattice)
library(rgdal)
library(classInt)
library(class)
library(e1071)
library(shapefiles)

### Import Shapefile ###
Jabar <- readOGR("D:/Document Bram/Michael Bram UI/SEMESTER 6/Spasial/Tugas/Tugas 3
(GWR)/petajawabaratminuswaduk/petajawabaratminuswaduk.shp")
plot(Jabar, main="Peta Jawa Barat")
head(Jabar)

### Import Data Peta ###
library(readxl)
datapeta <- read_excel("datapeta.xlsx", sheet = "datapeta digeser")
View(datapeta)
head(datapeta)

### Menampilkan Plot Peta Jawa Barat ###
plot(Jabar, density=16, col="grey", axes=T, cex.axis=.75)
title(main="Peta Jawa Barat", sub="Created with Rstudio",font.sub=2)
title(xlab="Longitude", ylab='Latitude',cex.lab=.75,line=2.25)
text(coordinates(Jabar), labels=Jabar$ADM2_EN, cex=.5)

```

```

### Merubah variabel pada data Shapefile menjadi variabel numerik ###
Jabar@data$ID <- as.numeric(row.names(Jabar@data))
Jabar@data$ID
Jabar@data$row <- as.numeric(row.names(Jabar@data))
Jabar@data$row

str(Jabar@data)
length(Jabar@data$ADM2_EN) #ADM2_EN adalah nama kabupaten/kota Jawa Barat di
Shapefile
length(Jabar@data$ID)

### Menggabungkan Shapefile dengan Data di Excel ###
temp <- merge(Jabar@data, Data, by="ID", all.Jabar=T, sort=F)
temp
Jabar@data <- temp[order(temp$row),]
Jabar@data

### Menggabungkan Shapefile dan Data di Excel dengan Data Peta ###
templ <- merge(Jabar@data, datapeta, by="ID", all.Jabar=T, sort=F)
templ
Jabar@data <- templ[order(templ$row),]
Jabar@data

### Layout ###
Data <- read_excel("ipm_jabar.xlsx")
Data.spdf <- SpatialPointsDataFrame(Jabar@data[,19:18], Jabar@data)
head(Data.spdf)

kabkot <- list('sp.pointLabel', Data.spdf, label=Jabar@data$ADM2_EN, cex=0.5,
col='black')
titik <- list('sp.points', Data.spdf, pch=16, cex=.8, col='blue')

#Plot Peta Residual Regresi Global
spplot(Jabar, 'er_ols', col.regions = brewer.pal(9,"Oranges"),
main="Plot Peta Residual Regresi Global",
scales = list(draw = TRUE),
sp.layout=list(kabkot, titik),
xlab="Longitude",
ylab="Latitude",
cuts=8)

#Plot Peta Residual Model GWR dengan Fungsi Pembobot Kernel Gaussian
spplot(Jabar, 'gwr_res', col.regions = brewer.pal(9,"PuRd"),
main="Plot Peta Residual Model GWR dengan Fungsi Pembobot Kernel Gaussian",
scales = list(draw = TRUE),
sp.layout=list(kabkot, titik),
xlab="Longitude",
ylab="Latitude",
cuts=8)

#Plot Peta IPM
spplot(Jabar, "y", col.regions=brewer.pal(9,"YlOrRd"), cuts=4,
main="IPM Jawa Barat 2021",
scales = list(draw = TRUE), sp.layout=list(kabkot, titik),
xlab="Longitude",
ylab="Latitude")

#Plot Region (Plot Peubah Signifikan)
spplot(Jabar, "gwr_t", col.regions=brewer.pal(5,"PuBu"),
main="Peta Sebaran Peubah Signifikan",
scales = list(draw = TRUE),
sp.layout=list(kabkot, titik),
xlab="Longitude",
ylab="Latitude",
cuts=3)

#Plot variabel X1
spplot(Jabar, "gwr_x1", col.regions=brewer.pal(9,"Reds"),

```

```

        main="Sebaran Koefisien X1",
        scales = list(draw = TRUE),
        sp.layout=list(kabkot, titik),
        xlab="Longitude",
        ylab="Latitude",
        cuts=8)

#Plot variabel X2
spplot(Jabar, "gwr_x2", col.regions=brewer.pal(9, "Greens"),
        main="Sebaran Koefisien X2",
        scales = list(draw = TRUE),
        sp.layout=list(kabkot, titik),
        xlab="Longitude",
        ylab="Latitude",
        cuts=8)

#Plot variabel X3
spplot(Jabar, "gwr_x3", col.regions=brewer.pal(9, "Purples"),
        main="Sebaran Koefisien X3",
        scales = list(draw = TRUE),
        sp.layout=list(kabkot, titik),
        xlab="Longitude",
        ylab="Latitude",
        cuts=8)

```

Lampiran 3. Kalibrasi Bandwidth Optimum (Kernel Gaussian)

```

> bw.mod.gwr.gauss<-bw.gwr(Y~X1+X2+X3, data=Data.spdf, approach="CV",
kernel="gaussian", adaptive=F)
Fixed bandwidth: 1.307802 CV score: 53.15359
Fixed bandwidth: 0.808428 CV score: 51.4385
Fixed bandwidth: 0.4997976 CV score: 47.54562
Fixed bandwidth: 0.3090535 CV score: 41.43676
Fixed bandwidth: 0.1911672 CV score: 67.52088
Fixed bandwidth: 0.3819113 CV score: 43.6981
Fixed bandwidth: 0.264025 CV score: 43.32098
Fixed bandwidth: 0.3368827 CV score: 41.94759
Fixed bandwidth: 0.2918542 CV score: 41.68471
Fixed bandwidth: 0.3196833 CV score: 41.52921
Fixed bandwidth: 0.302484 CV score: 41.46654
Fixed bandwidth: 0.3131138 CV score: 41.45331
Fixed bandwidth: 0.3065442 CV score: 41.43947
Fixed bandwidth: 0.3106044 CV score: 41.44012
Fixed bandwidth: 0.308095 CV score: 41.43658
Fixed bandwidth: 0.3075027 CV score: 41.43722
Fixed bandwidth: 0.3084612 CV score: 41.43647
Fixed bandwidth: 0.3086874 CV score: 41.43651
> bw.mod.gwr.gauss
[1] 0.3084612

```

Lampiran 4. Kalibrasi Bandwidth Optimum (Kernel Bisquare)

```
> bw.mod.gwr.bisq<-bw.gwr(Y~X1+X2+X3, data=Data.spdf, approach="CV",
kernel="bisquare", adaptive=F)
Fixed bandwidth: 1.307802 CV score: 50.80606
Fixed bandwidth: 0.808428 CV score: 79.02182
Fixed bandwidth: 1.616433 CV score: 52.44848
Fixed bandwidth: 1.117058 CV score: 47.18729
Fixed bandwidth: 0.999172 CV score: 41.9823
Fixed bandwidth: 0.9263143 CV score: 38.94364
Fixed bandwidth: 0.8812857 CV score: 43.7846
Fixed bandwidth: 0.9541435 CV score: 39.66054
Fixed bandwidth: 0.9091149 CV score: 39.0883
Fixed bandwidth: 0.9369441 CV score: 39.13648
Fixed bandwidth: 0.9197447 CV score: 38.90157
Fixed bandwidth: 0.9156845 CV score: 38.92608
Fixed bandwidth: 0.9222541 CV score: 38.90748
Fixed bandwidth: 0.9181938 CV score: 38.90534
Fixed bandwidth: 0.9207032 CV score: 38.90216
Fixed bandwidth: 0.9191523 CV score: 38.90229
Fixed bandwidth: 0.9201108 CV score: 38.90154
> bw.mod.gwr.bisq
[1] 0.9201108
```

Lampiran 5. Hasil Analisis GWR dengan Analisis Regresi Global

```
*****
*                               Results of Global Regression                               *
*****

Call:
lm(formula = formula, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-2.3174 -0.7692 -0.1250  0.8877  1.8290

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 29.6106204  5.7780215   5.125 3.43e-05 ***
X1           0.0013073  0.0001612   8.112 3.38e-08 ***
X2           2.2849043  0.4266778   5.355 1.94e-05 ***
X3          -0.1146074  0.1254520  -0.914    0.37

---Significance stars
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 1.21 on 23 degrees of freedom
Multiple R-squared: 0.9434
Adjusted R-squared: 0.936
F-statistic: 127.7 on 3 and 23 DF, p-value: 1.753e-14
***Extra Diagnostic information
Residual sum of squares: 33.68557
Sigma(hat): 1.160785
AIC: 92.59596
AICc: 95.4531
BIC: 88.55433
*****
```

Lampiran 6. Hasil Analisis GWR dengan Kernel Gaussian

```
*****
*               Results of Geographically Weighted Regression               *
*****

*****Model calibration information*****
Kernel function: gaussian
Fixed bandwidth: 0.3084612
Regression points: the same locations as observations are used.
Distance metric: Euclidean distance metric is used.

*****Summary of GWR coefficient estimates:*****
              Min.      1st Qu.      Median      3rd Qu.      Max.
Intercept  8.75117333 15.19963008 28.57739250 32.68833620 38.3205
X1          0.00052869 0.00085511 0.00094976 0.00189701 0.0022
X2          1.26899081 2.25953407 2.77995825 3.28496117 4.0639
X3         -0.58019336 -0.36234328 -0.05157794 0.20465676 0.3063
*****Diagnostic information*****
Number of data points: 27
Effective number of parameters (2trace(S) - trace(S'S)): 19.34643
Effective degrees of freedom (n-2trace(S) + trace(S'S)): 7.653573
AICc (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): 140.6132
AIC (GWR book, Fotheringham, et al. 2002, GWR p. 96, eq. 4.22): 55.05187
BIC (GWR book, Fotheringham, et al. 2002, GWR p. 61, eq. 2.34): 64.72341
Residual sum of squares: 6.721578
R-square value: 0.988703
Adjusted R-square value: 0.9558549

*****
```

Lampiran 7. Hasil Analisis GWR dengan Kernel Bisquare

```
*****
*               Results of Geographically Weighted Regression               *
*****

*****Model calibration information*****
Kernel function: bisquare
Fixed bandwidth: 0.9201108
Regression points: the same locations as observations are used.
Distance metric: Euclidean distance metric is used.

*****Summary of GWR coefficient estimates:*****
              Min.      1st Qu.      Median      3rd Qu.      Max.
Intercept  8.62655455 16.43773688 28.34141655 32.31086597 38.3470
X1          0.00051207 0.00075739 0.00105555 0.00179499 0.0023
X2          1.26538788 2.16938290 2.78929264 3.48033846 3.7418
X3         -0.58524830 -0.34736972 -0.03455825 0.16750649 0.3290
*****Diagnostic information*****
Number of data points: 27
Effective number of parameters (2trace(S) - trace(S'S)): 16.11378
Effective degrees of freedom (n-2trace(S) + trace(S'S)): 10.88622
AICc (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): 118.6738
AIC (GWR book, Fotheringham, et al. 2002, GWR p. 96, eq. 4.22): 61.54554
BIC (GWR book, Fotheringham, et al. 2002, GWR p. 61, eq. 2.34): 66.13108
Residual sum of squares: 9.280155
R-square value: 0.9844028
Adjusted R-square value: 0.9589804

*****
```

Lampiran 8. Tabel Nilai Dugaan Parameter Model GWR dengan Kernel Bisquare

Kab/Kota	β_1	β_2	β_3
Bandung	0,000683519	2,706264899	-0,47921241
Bandung Barat	0,000636789	2,789930472	-0,472661284
Bekasi	0,000877979	3,532590252	-0,072558389
Bogor	0,00094358	4,06393281	0,000846091
Ciamis	0,001937076	1,623313686	0,199886601
Cianjur	0,000949761	3,234253261	-0,168706611
Cirebon	0,002006638	2,993965725	0,294748682
Garut	0,001260861	1,999424677	-0,158459194
Indramayu	0,000886839	2,779958246	-0,467994771
Karawang	0,000840262	3,33566907	-0,134758576
Kota Bandung	0,000612493	2,718292156	-0,498620054
Kota Banjar	0,002024389	1,464777458	0,194844248
Kota Bekasi	0,000877481	3,654363841	-0,068553582
Kota Bogor	0,001037898	3,82744977	0,025889545
Kota Cimahi	0,000591798	2,747548694	-0,504423528
Kota Cirebon	0,002019583	2,9545732	0,306324616
Kota Depok	0,000872301	3,931493938	-0,05157794
Kota Sukabumi	0,001309452	3,398479784	0,133231297
Kota Tasikmalaya	0,001856948	1,591543071	0,209467394
Kuningan	0,001942482	2,087209659	0,209426915
Majalengka	0,00151504	2,431858472	0,042572448
Pangandaran	0,002194664	1,268990812	0,223270032
Purwakarta	0,000637322	2,992076951	-0,367499757
Subang	0,000528688	2,624037117	-0,580193364
Sukabumi	0,001578873	3,200190102	0,228095993
Sumedang	0,000869961	2,446624911	-0,357186797
Tasikmalaya	0,001953352	1,428341134	0,217608841

Lampiran 9. Tabel p-value Tingkat Signifikansi Parameter

Kab/Kota	P_1	P_2	P_3
Bandung	0,007	0	0,029
Bandung Barat	0,009	0	0,063
Bekasi	0,006	0,001	0,814
Bogor	0,005	0	0,998
Ciamis	0	0,008	0,257
Cianjur	0	0,001	0,539
Cirebon	0	0	0,142
Garut	0	0,001	0,334
Indramayu	0,008	0,001	0,096
Karawang	0,004	0	0,606
Kota Bandung	0,012	0	0,022
Kota Banjar	0	0,02	0,283
Kota Bekasi	0,006	0	0,826
Kota Bogor	0,001	0	0,921
Kota Cimahi	0,016	0	0,031
Kota Cirebon	0	0	0,129
Kota Depok	0,007	0	0,866
Kota Sukabumi	0	0	0,635
Kota Tasikmalaya	0	0,006	0,224
Kuningan	0	0,002	0,255
Majalengka	0	0	0,753
Pangandaran	0	0,055	0,236
Purwakarta	0,004	0	0,067
Subang	0,024	0,001	0,004
Sukabumi	0,003	0,005	0,536
Sumedang	0	0	0,021
Tasikmalaya	0	0,012	0,226